

AI 공방전 기반 무인체계 복합 공격

작전명 "그림자 군집(Shadow Swarm)"

— 쉬운 설명본 —

UAV 군집 + UGV를 대상으로, 공격 AI와 방어 AI가 맞붙는 클라우드 시뮬레이션 환경을 전제로 설계한 복합 공격 시나리오를 비전문가도 읽을 수 있게 풀어 쓴 문서

문서 성격	예선 보고서 4장(공격 시나리오)·6장(AI 에이전트) 초안 · 개념 설계 수준
대상 환경	클라우드 UAV/UGV 시뮬레이터 · 사람 운용자 개입 없음(AI vs AI)
주의	본 문서의 공격 기법은 대회 시뮬레이션 방어 설계 목적의 개념 서술이다.

1 한눈에 보기

한 줄 요약

드론에 **미리 약점을 심어두거나 실시간으로 약점을 유발**하고, 작전 중 **GPS·통신·센서를 티 안 나게 흔들어** 방어 AI의 감시망을 피한 뒤, 드론 한 대의 오판을 **편대 전체로 전염**시켜 임무를 무너뜨리는 공격이다.

이 문서는 우리 팀이 설계한 공격 시나리오를 전문용어를 걷어내고 쉽게 풀어 쓴 것이다. 핵심만 먼저 말하면, 이 공격은 방어 시스템을 정면으로 부수지 않는다. 대신 방어가 믿고 있는 '**서로 교차확인**'이라는 **안전장치의 전제 자체를 먼저 흔들어**, 방어가 스스로 공격을 정상으로 착각하게 만든다.

쉬운 비유 — 시험 부정행위

① 시험 전에 몰래 책상에 커닝 장치를 붙여둔다(평소엔 안 보임). ② 시험 당일 조명을 깜빡거리게 해 감독관 시야를 흐린다. ③ 감독관이 못 볼 때 커닝한다. ④ 내 틀린 답을 옆 사람들이 '재가 맞겠지' 하고 베낀다. ⑤ 끝나고 커닝 장치를 떼어내 증거를 없앤다. — 이 다섯 단계가 그대로 드론 공격에 대응된다.

2 대회 환경 전제 — 사람은 없고, AI끼리 싸운다

이 시나리오는 실제 전장이 아니라 **클라우드 시뮬레이터**에서 벌어지는 대결을 전제로 한다. 가상의 UAV 군집과 UGV가 돌아가고, **우리 공격 AI와 상대 방어 AI**가 같은 데이터를 실시간으로 보며 맞붙는다. 사람 운용자는 경기 중에 개입하지 않는다.

이 전제 때문에 공격 설계가 달라진다. 물리적인 재밍 장비나 현장 접근이 필요 없고, 대신 **시뮬레이터가 열어주는 통로(메시지·센서 데이터·네트워크)**를 통해 공격한다. 현실 공격 개념을 시뮬 환경으로 옮기면 다음과 같다.

현실(물리 전장)에서라면	시뮬레이션 환경에서는	비고
GPS 신호 기만 장비	위조된 위치 메시지를 주입	항법 교란
전파 방해(재밍) 장비	통신 패킷을 지연·손실·재전송	통신 교란
현장에 물리 표식 노출	센서 입력 데이터에 미세 변형	인식 교란
부품·정비 공급망 침투	학습 데이터/모델 오염(규칙 허용 시)	사전 약점 심기
사람 운용자 속이기	해당 없음 — 운용자가 없음	삭제됨

여기서 오는 결론

'사람이 감시하지 않는 순간을 만든다' 같은 고민은 필요 없다(항상 그러니까). 대신 공격의 승패는 오직 하나 — **상대 방어 AI를 어떻게 이기느냐**로 좁혀진다.

3 공격의 핵심 아이디어 3가지

복잡해 보이지만, 이 공격을 지탱하는 생각은 세 가지뿐이다.

아이디어	무슨 뜻인가	왜 강한가
① 저강도로 살살	여러 공격을 각각 '경보가 울리지 않을 만큼' 약하게 동시에 건다.	방어는 보통 '일정 수준 넘으면 경보' 방식. 그 선 아래로 기면 안 걸린다.

아이디어	무슨 뜻인가	왜 강한가
② 편대로 전염	드론 한 대의 오판을 편대 협업 통신으로 다른 드론에 퍼뜨린다.	한 대만 뚫어도 여러 대가 함께 오판. 방어가 가장 잡기 어려운 계층.
③ 상대를 보고 맞춤	방어 AI의 반응을 관찰해 그 약점에 맞춰 공격을 바꾼다.	고정 각본이 아니라 적응형이라, 방어가 대응해도 다시 피해간다.


4 공격 시나리오 — 단계별로 쉽게

실제 대결에서 공격 AI가 하는 일을 순서대로 풀면 다음과 같다. 각 단계는 **바로 앞 단계가 만들어 준 틈** 위에서 성립한다는 점이 핵심이다.

단계	공격 AI가 하는 일 (쉬운 설명)	노리는 것
0. 사전 약점 (조건부)	규칙이 학습·준비 단계를 허용하면, 표적 식별 AI에 '특정 무늬를 보면 판단을 뒤집는' 스위치를 심어둔다. 허용 안 하면 이 단계는 건너뛰고, 같은 효과를 3단계에서 실시간으로 만든다.	정상 검사를 통과하는 숨은 약점
1. 떠보기(정찰)	작은 교란을 슬쩍 던져 방어 AI가 어디서 반응하는지 관찰한다. 이걸로 방어의 '경보 기준선'을 알아낸다.	상대의 탐지 한계선 파악
2. 안개 만들기	위치(GPS)·통신·센서 신호를 아주 조금씩 흔들다. 각각은 '그냥 오차'로 보일 만큼 약하게. 이걸로 교차확인 안전장치의 기준점을 미리 오염시킨다.	방어의 교차확인 무력화 준비
3. 오판 유도	기준점이 흔들린 틈에 표적 식별을 뒤집는다. 이때 AI는 오히려 '확신 90%'라고 당당히 틀린 답을 내서, '신뢰도 급락' 같은 탐지 신호도 뜨지 않는다.	높은 확신의 잘못된 판단
4. 편대 전염	오판한 드론이 '저기 적 있음(확신 90%)'을 편대에 방송한다. 다른 드론들은 협업 규칙에 따라 이를 받아들여 함께 오판한다. UGV도 같은 정보로 엉뚱한 길로 간다.	한 대의 오판 → 편대 전체
5. 마무리·은폐	임무 실패·구역 이탈 같은 '채점되는 나쁜 결과'를 만들고, 통신을 흐트러뜨려 기록을 최소화한다. 사후 분석은 '단순 센서 오차'로 보이게 한다.	성과 달성 + 원인 추적 방해

5 왜 방어 AI가 못 막나 — '합칠 때만 위험'

이 공격의 가장 영리한 부분이다. 방어 AI는 대개 '위험이 일정 선을 넘으면 경보'를 울린다. 그런데 우리는 **어떤 공격도 그 선을 혼자서는 넘지 않게** 약하게 유지한다. 위험은 **여러 공격이 같은 순간에 겹칠 때만** 임계선을 넘는다.



[그림 1] 개별 공격 벡터는 각각 탐지 임계치 아래에 머물지만, 시간축에서 겹치면 합산 위험만 임계선을 넘는다.

핵심 문장

개별 공격은 하나하나 보면 '정상 범위의 사소한 오차'다. 그래서 방어는 각각을 '감시 강화·조건부 수용' 정도로 넘긴다. **겹침(합산)을 보지 않는 한** 이 공격은 경보를 울리지 않는다.

바꿔 말하면, 이 공격을 막는 방법은 분명하다 — 방어가 **개별 신호가 아니라 여러 신호의 '시간적 상관관계'**를 함께 보도록 바꾸면 된다. 이 지점이 우리 보고서 방어 전략(5장)의 출발점이 된다.

6 공격 AI 에이전트는 어떻게 움직이나

이 공격은 정해진 각본을 따라가는 프로그램이 아니라, 상대를 보고 스스로 판단하는 **여러 역할의 AI 에이전트가 협력**하는 구조다. 상대(방어 AI)가 적응형이기 때문에, 우리도 적응형이어야 한다.

에이전트	맡은 일
정찰 에이전트	방어 AI의 반응을 관찰해 '경보 기준선'과 대응 방식을 추정한다.
조율 에이전트	지금 어떤 공격 조합이 안전한지 판단하고 타이밍을 맞춘다(사령탑).
교란 에이전트	위치·통신·센서 교란의 세기를 실시간으로 미세 조절한다.
오판 유도 에이전트	표적 식별을 뒤집는 입력을 현장 조건에 맞게 만들어 낸다.
전염 예측 에이전트	'지금 오판을 넣으면 편대 몇 대까지 퍼질지' 미리 시뮬레이션한다.
은폐 에이전트	각 공격이 탐지 한계에 근접하는지 감시하고, 넘으려 하면 세기를 낮춘다.

판단 흐름 (관찰 → 판단 → 실행 → 적응)

① 방어 반응을 **관찰**한다 → ② 지금 열린 약점과 성공 확률을 **판단**한다 → ③ 조건이 맞으면 여러 교란을 **동시에 실행**한다 → ④ 결과를 보고 **다시 조정**한다. 조건이 안 맞으면 무리하지 않고 기다린다. 그래서 특정 가정 하나가 틀려도 공격 전체가 무너지지 않는다.

비가역적이거나 큰 결과를 내는 행동(예: 교전 유발)은 곧바로 실행하지 않고 **정책 게이트**를 한 번 거치게 설계한다. 이는 방어 측이 '치명적 제어는 사람 승인을 거친다'고 설계한 것과 대칭을 이루며, 오판·부수 피해 위험을 통제하기 위한 장치다.

7 이 시나리오의 가정과 한계 (정직하게)

이 공격이 성립하려면 아래 조건이 필요하며, 알려진 한계도 분명하다. 이를 숨기지 않고 밝히는 것이 설계의 성숙도를 보여준다.

구분	내용
가정 1	시뮬레이터가 위치·통신·센서 입력을 외부에서 건드릴 수 있는 통로를 노출한다.
가정 2	표적 식별·자율 판단·편대 협업을 AI가 수행한다(그래야 오펜·전염이 성립).
가정 3	편대가 서로의 판단을 신뢰가중으로 채택한다(전염의 전제).
한계 1	대회 규칙·시물 인터페이스·채점 방식이 아직 공개되지 않아, 세부는 규칙 확정 후 조정이 필요하다.
한계 2	‘사전 약점 심기(0단계)’는 학습·준비 단계를 규칙이 허용할 때만 가능하다. 아니면 실시간 방식으로 대체한다.
한계 3	방어가 ‘여러 신호의 시간적 상관관계’를 보도록 설계되면, 이 공격의 최대 강점(탐지 회피)이 약해진다.
한계 4	본 문서는 개념 설계이며, 실제 시물 환경에서의 실증은 별도 검증이 필요하다.

한계를 밝히는 이유

위 한계들은 약점이 아니라 오히려 강점이다. 특히 **한계 3**은 우리 공격을 무너뜨리는 방법이 곧 우리 **방어 전략의 정당성**을 보여준다 — 공격과 방어가 하나의 논리로 이어진다는 뜻이다.

8 맺음

정리하면, ‘그림자 군집’ 공격은 세 가지 — **저강도 다중 교란**, **편대 전염**, **상대 적응** — 을 하나로 엮어, 방어 AI의 탐지망을 피하면서 임무를 무너뜨리는 복합 시나리오다. 각 공격 요소는 방어 문서가 개별적으로 나눠 놓은 위협들이지만, 이 시나리오는 그것들을 **서로가 서로를 돕는 연쇄**로 결합해 개별 방어의 사각지대를 정확히 겨냥한다.

다음 단계로는 ① 공격 AI 에이전트 아키텍처 상세 설계(6장), ② 이 공격을 잡기 위한 ‘시간 상관 기반 탐지’ 방어 설계(5장) 연결, ③ 시물 규칙 확정 후 인터페이스 매핑을 진행한다.