

DAH 방어 전략 수립

서두

- 본 방어 전략은 특정 오픈소스 오토파일럿 취약점(ex. PX4, MAVLink)에 종속되지 않고, UAV/UGV에 공통적으로 존재하는 통신, 항법, 센서, AI 모델, 제어기, 정비/업데이트 계층을 기준으로 위협을 식별하고 방어 요구사항을 도출하는 것을 목적으로 한다.
- 또한 본 방어 전략은 방어하는 입장을 고려하여 정적 분석과 동적 분석을 둘 다 사용하고 설계 단계 위협모델링과 운용 단계 런타임 검증을 결합한다.

UAV(무인항공기)/UGV(무인지상차량)에 사용할 위협 모델

TARA(ISO/SAE 21434 표준)를 이용한 위협 모델 구현

TARA(Threat Analysis and Risk Assessment)란?


- 자산, 피해 시나리오, 공격경로, 공격 가능성, 영향도를 체계적으로 분석하여 위험도를 산정하는 절차이다.
- 특정 장비의 취약점을 파악하고 적절한 보완 활동을 수행하는 것이 목표이다.
- 일반적인 절차는 위협 요소 식별, 위협 평가, 위협 검증의 절차를 거치며 이를 반복하는 구조를 가지고 있다.
- UAV/UGV에 모두 적용 가능하나 TARA만 사용하면 구성요소 간의 상호작용 때문에 생기는 위험 등을 놓칠 수 있다. 이에 따라 TARA를 중심 골격으로 두고 추가적인 위협 모델링을 통해 보완하는 것이 필요하다

위협 모델링

- 시스템이나 소프트웨어의 직면한 잠재적 위협을 사전에 식별하고 분석하여 이에 따른 리스크를 관리하기 위한 접근법
- 위협 모델링 식별을 위한 다양한 프레임 워크 존재 (ex. STRIDE, STPA-Sec 등)
- TARA 위협 모델에 STRIDE와 같은 위협 모델링을 통하여 한층 더 정교화된 모델을 완성시킬 수 있음

전체 프레임

UAV/UGV 각각을 살펴보기 전에 아래와 같이 전체 프레임 구조를 도식화하였다.



위 그림을 보면 UAV와 UGV를 바로 위협 목록으로 분석하지 않고, 먼저 **작전 대상, 임무 환경, 시스템 구조**를 정의한 뒤 TARA로 위협을 평가하는 흐름을 가지고 있다.

TARA를 가운데에 둔 이유는 TARA가 “무엇이 중요한 자산인지”, “침해되면 어떤 피해가 생기는지”, “공격자가 어떤 경로로 접근할 수 있는지”, “그 위험이 얼마나 큰지”를 정리하는 기본 골격이기 때문이다.

다만 UAV/UGV는 단순 IT 시스템이 아니라 자율주행·자율비행·센서·제어·AI가 얹힌 사이버-물리 시스템(CPS)이기에 TARA 하나만으로는 부족하고, 아래 여러 모델들을 보조로 사용했다.

STRIDE는 위협을 Spoofing, Tampering(데이터/명령 변조), Repudiation, Information Disclosure, Denial of Service, Elevation of Privilege의 6가지로 나누는 모델로, C2(Command & Control) 링크, 센서, 제어기, 정비 포트, 그리고 UAV를 조종하는 지상통제체계인 GCS와 같은 구성요소별 위협을 빠짐없이 뽑기 위해 사용했다.

STPA-Sec는 안전공학 기반 보안 분석 방법으로 특히 자율주행·자율비행처럼 제어와 안전이 중요한 시스템에 유용하다. 잘못된 제어행동, 안전모드 전환 실패, 위험 상황에서의 지연 대응처럼 안전과 보안이 연결되는 문제를 보기 위해 사용했다.

MITRE ATLAS는 AI 시스템을 대상으로 한 공격 기법을 정리한 프레임워크로 적대적 예제, 데이터 중독, 모델 백도어, 모델 추출처럼 AI 고유 위협을 반영하기 위해 사용했다.

IEC 62443/NIST는 산업제어시스템/운영기술 보안 표준으로 운용망, 통제망, 정비망, 조직 차원의 위험관리 기준을 반영하기 위해 사용했다.

마지막을 **방어 요구사항**과 **방어 AI 에이전트**로 이어지게 한 이유는, 위협모델링의 목적이 분석에서 끝나는 게 아니라 실제 방어체계 설계로 연결하기 위해서이다.

UAV 사이버보안 위협 모델

TARA는 차량 사이버 보안 표준이기에 UAV에 적용은 가능하나 부족한 부분이 존재한다.

이에 추가로 현재 UAV에 사용되는 AI를 고려하기 위해 한국기술학회 2026 논문 '군용 드론/UAV에 대한 AI 적용과 사이버보안 취약요소에 관한 동향 연구'를 참고했다.

이 논문에서는 군용 드론의 AI 적용 영역을 크게 세 가지로 나눈다.


1. **인식 영역**: 표적 탐지, 객체 식별, 영상 분류, 이동 표적 추적
2. **기동 영역**: 자율비행, 경로계획, 장애물 회피, 충돌 방지 기능
3. **협업 영역**: 군집 제어, 임무 재할당, 탈중앙 지휘통제 같은 기능

AI를 도입하면서 보안 측면에서는 위협이 세 단계로 확장된다고 본다.

기존에는 **재밍, GPS 스푸핑, 통신 도청, 하이재킹, GCS 침해** 같은 통신·항법·제어 위협이 중심이었다면 AI가 들어가면서 **적대적 예제, 데이터 중독, 모델 추출, 백도어 공격**처럼 AI의 입력·학습·모델 자체를 노리는 위협이 중요해졌다. 여기에 군집드론으로 확장되면 손상된 한 대의 드론이나 왜곡된 정보가 전체 편대의 판단과 임무 실패로 이어질 수도 있기에 더욱 보안의 중요성이 커진 것을 알 수 있다.

앞으로 군용 드론 보안은 개별 부품이나 통신 링크만 보호하는 방식으로는 부족하다. 위 논문에서는 **플랫폼 보호, 통신·항법 보안, AI 모델과 데이터 검증, 군집 협업 알고리즘 안정성, 이상 전파 통제**를 하나의 체계로 통합해 다뤄야 한다고 주장한다.

위 내용을 토대로 아래와 같이 도식을 작성했다



이 그림은 UAV만 따로 떼어, UAV의 작동 구조와 주요 공격표면을 보여준다. 영역을 네 개로 나눈 이유는 UAV 위협이 한 기체 내부에서만 생기지 않기 때문이다.

지상 운용 영역에는 GCS와 운용자/임무계획을 배치했다. UAV는 지상통제체계에 크게 의존하므로 GCS가 침해되면 임무계획 변조, 명령 주입, 영상 탈취 같은 문제가 생길 수 있다.


전술 통신 영역에는 C2/Telemetry(원격 측정 데이터) Link와 암호/인증을 넣었다. 논문에서도 기존 UAV 보안의 핵심 위협으로 재밍, 도청, 하이재킹, 위조 명령 주입을 언급했다. 그래서 통신 링크는 UAV 위협모델에서 반드시 별도 영역으로 잡아야 한다.

UAV 탑재 영역에는 Flight Controller, GNSS(위성항법 시스템)/INS(관성항법장치), 센서 계층, AI Mission Core, 페이로드/구동부를 배치했다. 이 구조는 위 논문에서 말한 UAV 기본 아키텍처와 복합 UAV 기능 계층을 반영한 것이다. 특히 AI Mission Core는 표적식별, 경로계획, 군집협업 판단을 수행하므로 기존 드론과 AI 기반 드론을 구분하는 핵심 요소이다.

AI/MLOps 공급망을 별도 영역으로 둔 이유는 AI 위협이 운용 중 입력값에서만 발생하는 것이 아니라, 학습데이터·라벨·모델 업데이트 과정에서도 발생하기 때문이다. 데이터 중독이나 모델 백도어는 바로 이 공급망 영역에서 생기는 대표 위협이다.

방어 포인트: 링크 인증, 암호화, GNSS/INS/비전 교차 검증, 센서 이상탐지, 모델 서명 검증, 군집 노드 신뢰도 평가

UGV 사이버보안 위협 모델



UGV는 지상에서 움직이기 때문에 **SLAM, 지도, 장애물 인식, 조향, 제동, 정비 포트, 물리 접근**이 훨씬 중요하다. 그래서 UAV 그림의 GNSS/INS 중심 구조와 달리, UGV 그림에는 위치/지도, 센서 계층, AI Autonomy Core, Drive-by-Wire 성격의 구동/임무 모듈을 강조했다.

원격 운용 영역에는 UGV를 원격 조종하는 운용자 콘솔인 OCU와 임무계획을 넣었다. UAV의 GCS와 유사하지만, UGV에서는 차량의 경로, 제한구역, 안전한계, 정지 조건이 특히 중

요하다.

전술 네트워크 영역은 원격 탈취와 명령 변조를 보기 위해 넣었다. UGV가 네트워크를 통해 명령을 받는다면, 잘못된 명령 하나가 충돌, 임무구역 이탈, 장비 탈취로 이어질 수 있다.

UGV 탑재 영역에서는 AI Autonomy Core가 장애물 인식, 경로계획, 위협판단을 담당한다. 여기서 센서 블라인딩이나 객체 오인식이 발생하면 단순 인식 오류가 아니라 실제 충돌이나 정지 실패로 이어질 수 있다.

정비/공급망 영역을 크게 잡은 이유는 UGV가 UAV보다 물리 접근 가능성이 높기 때문이다. 지상 장비는 회수, 정비, 포트 연결, 부품 교체, OTA 업데이트가 자주 발생하므로 USB, Debug, CAN, Ethernet, 펌웨어, 공급망 공격이 중요한 위협이 된다.

방어 포인트: OCU 인증, 메시지 무결성, SLAM/지도 검증, 센서 융합, OTA 서명 검증, 정비 포트 접근통제

방어 아키텍처의 견고성 및 실현 가능성

방어 전략

방어 계층	목적	적용 예시
예방	공격 성공 가능성 감소	인증, 암호화, 서명검증, 접근통제
탐지	이상징후 조기 식별	GNSS-INS 불일치, 명령 빈도 이상, 센서 신뢰도 급락
대응	피해 확산 차단	명령 차단, 링크 전환, 안전모드, 귀환/정지 권고
복구	정상 상태 회복	모델/펌웨어 롤백, 임무 재계획, 안정 버전 복구
개선	방어체계 고도화	사고 로그 기반 위협모델 업데이트

- 본 방어 아키텍처는 단일 보안통제에 의존하지 않고 예방, 탐지, 대응, 복구, 개선의 다계층 방어 구조로 설계하였다. 이는 통신 암호화가 우회되더라도 명령 정책 검증과 런타임 이상탐지를 통해 피해를 제한하고, 센서 교란이 발생하더라도 다중 센서 교차검증과 안전모드 전환을 통해 임무 실패로의 확산을 억제하기 위함이다.

실현 가능성

- 한국 방산 무인체계는 업체별 자체 개발 소프트웨어와 폐쇄형 인터페이스를 사용하는 경우가 많으므로, 특정 오픈소스 오토파일럿이나 공개 취약점에 종속된 방어 전략은 실효성이 제한될 수 있다. 이에 본 전략은 제조사별 내부 구현이 공개되지 않더라도 공통적으로 확보 가능한 텔레메트리, 네트워크 상태, 센서 출력, AI 추론 결과, 임무 맥락, 시스템 로그를 기준으로 방어 판단을 수행하도록 설계하였다.


- 위험을 처리하는데 있어 실현 가능성을 높이기 위해서는 위험 수준에 따른 위험 처리를 다르게 해야 한다.

위험 수준	기본 선택	설명
Critical	회피 + 감소	추락, 충돌, 아군 피해, 임무체계 장애처럼 치명적 결과가 예상되면 해당 기능 사용 중단, 임무 중지, 안전모드 전환을 우선한다. 동시에 원인 제거를 위한 기술적 완화책을 적용한다.
High	감소 중심, 필요시 회피	GPS 스푸핑, C2 명령 변조, 악성 업데이트처럼 임무 실패나 제어권 상실로 이어질 수 있는 위험은 통제 적용, 탐지 강화, 대응 플레이백으로 위험을 낮춘다. 위험이 낮아질 때까지 자율기능 제한도 가능하다.
Medium	감소 + 조건부 수용	센서 신뢰도 저하, 일시적 통신 품질 저하처럼 통제 가능한 위험은 감시 강화와 제한적 운용 조건을 붙여 수용할 수 있다.
Low	수용	영향이 작고 발생 가능성이 낮은 위험은 로그 수집과 주기적 점검을 조건으로 수용한다.
공급망/정비 위험	감소 + 전가	납품업체, 정비업체, 소프트웨어 공급망에서 발생하는 위험은 계약상 보안 요구사항, 패치 SLA, 취약점 대응 의무, 검증 자료 제출로 일부 전가한다. 단, 작전·안전 책임 자체는 전가하지 않는다.

- 한국 방산 무인체계는 폐쇄형 구조, 장기 운용주기, 다수 협력업체 기반 공급망, 제한적인 현장 패치 환경을 갖기 때문에 모든 위험을 제거하는 방식은 현실적이지 않다. 따라서 본 전략은 위험 수준에 따라 차등적인 위험 처리 방식을 적용한다. 특히 군용 UAV/UGV에서는 작전 안전, 아군 피해, 기밀 유출과 직접 연결되는 위험은 비용 효율성보다 임무 안전성과 통제 가능성을 우선하여 회피 또는 강한 감소를 우선한다. 또한 통제 가능한 중간 위험은 탐지와 대응 체계를 전제로 조건부 수용하며, 공급망·정비·업데이트 관련 위험은 계약상 보안 요구사항과 검증 의무를 통해 일부 전가한다.

위험 모델 기반 방어 AI 에이전트 운용 개념

TARA/STRIDE/STPA-Sec/ATLAS 결과를 실시간 탐지와 대응 추천에 연결



왼쪽 입력 데이터에는 Telemetry, Network/RF(무선 주파수), Sensor/AI Output, Mission Context를 넣었다. 방어 AI 에이전트가 상황을 판단하려면 단순 로그만 보는 것이 아니라, 위치·자세·속도, 통신상태, 센서 신뢰도, 모델 출력, 임무계획, 제한구역을 함께 봐야 하기 때문이다.

Threat Model KB는 TARA, STRIDE, STPA-Sec, MITRE ATLAS 결과를 지식베이스로 만든다는 뜻이다. 예를 들어 “GNSS와 INS가 급격히 불일치한다”는 이벤트가 들어오면, 에이전트는 이를 TARA의 “비행/주행 경로 왜곡” 피해 시나리오와 연결하고, STRIDE의 Spoofing 또는 Tampering 가능성, STPA-Sec의 불안전 제어행동 가능성으로 해석할 수 있다.

Defense AI Agent는 직접 모든 제어를 수행하는 존재가 아니라, 상황해석, 위협매핑, 이상 탐지, 위험 재평가를 담당하는 구조를 가지고 있다. UAV/UGV는 안전 문제가 크기 때문에 AI 에이전트가 치명적 제어권을 단독으로 갖는 것은 위험하기 때문이다.

오른쪽에는 대응을 세 단계로 나눴는데, 저위험 자동조치는 로그 수집, 센서 재검증, 통신채널 전환처럼 자동화해도 비교적 안전한 조치이다. 고위험 조치는 임무중단, 강제정지, 귀환, 제어권 전환처럼 인간 승인이거나 정책 엔진이 필요한 조치이다. 증거보존은 사후 분석과 모델 개선, 위협모델 업데이트를 위해 필요하다.

운용 원칙: AI 에이전트는 탐지, 분석, 권고, 저위험 자동조치를 담당하고 치명적 제어는 정책 엔진과 인간 승인절차를 둔다.

구체적인 공격 시나리오와 그에 대한 방어 예시

공격 시나리오	탐지 신호	방어 전략	대응	검증 방법
GNSS/GPS 스푸핑	GNSS 위치와 INS/비전/	다중 항법 교차검증, GNSS 신뢰도	GNSS 의존도 하향, 안전항법 전	시뮬레이터에서 위치 좌표에 인위

공격 시나리오	탐지 신호	방어 전략	대응	검증 방법
	지도 위치 불일치	점수화	환, 귀환/정지 권고	적 오차를 주입하고, GNSS-INS-비전 기반 위치 차이가 임계값을 넘을 때 탐지되는지 확인
C2 명령 변조	비정상 명령 빈도, 미승인 명령, 인증 실패	명령 서명검증, 명령 정책 엔진, 상태 기반 명령 허용	명령 차단, 운용자 재인증, 링크 전환	정상 운용 상태에서 허용되지 않은 명령, 재전송 명령, 순서가 어긋난 명령을 주입하고 정책 엔진이 차단하는지 확인
통신 재밍/DoS	패킷 손실, 지연 급증, RF 품질 저하	다중 링크, 임무 지속 모드, 통신두절 안전정책	자율 안전모드, 사전 정의 경로 복귀	네트워크 에뮬레이터로 지연, 패킷 손실, 대역폭 제한을 단계적으로 증가시키고 링크 전환 및 통신두절 안전정책이 작동하는지 확인
AI 적대적 예제	모델 신뢰도 급락, 센서 간 판단 불일치	다중 센서 합의, 입력 이상탐지, 신뢰도 기반 판단 제한	인간 확인 요청, 표적판단 보류	이미지/센서 입력에 노이즈, 패턴, 조명 변화, 부분 가림을 적용하고 AI 신뢰도 변화와 센서 간 불일치 탐지가 가능한지 확인
모델/펌웨어 변조	서명 불일치, 업데이트 직후 이상행동	업데이트 서명검증, 롤백, 모델 버전 감사	업데이트 차단, 이전 안정 버전 복구	서명이 없는 업데이트, 해시가 다른 모델 파일, 비정상 버전 번호를 배포 시나리오에 넣고 차단·롤백 여부를 확인
UGV SLAM/지도 오염	지도와 실시간 센서 관측 불일치	지도 무결성 검증, 제한구역 정책, 경로 검증	경로 재계산, 저속 모드, 안전정지	지도 일부를 변경하거나 가짜 장애물/경로를 삽입한 뒤, 실시간 LiDAR/카메라 관측과 지도 불일치

공격 시나리오	탐지 신호	방어 전략	대응	검증 방법
				가 탐지되는지 확인

- 위 표는 공격 유형별로 예방, 탐지, 대응, 검증 방법을 연결한 것으로, 본 방어 전략이 단순한 정책 제안이 아니라 운용 환경에서 검증 가능한 대응 체계임을 보여준다.
- 또한 위 검증 방법은 실제 방산 UAV/UGV 인터페이스가 공개되지 않은 상황을 고려하여, 특정 장비 종속 API가 아니라 시뮬레이터, 네트워크 에뮬레이터, 로그 리플레이, 센서 입력 변형을 활용하는 방식으로 설계하였다. 이를 통해 폐쇄형 방산 플랫폼에서도 공통 관측 데이터 기반 방어 전략의 타당성을 검증할 수 있다.

방어 에이전트의 역할

이에 따라 방어 에이전트가 해야하는 일은 다음과 같다.

1. 데이터 수집

입력	수집 내용
Telemetry	위치, 속도, 자세, 고도, 배터리, 비행/주행 모드, 제어 상태
Network/RF	통신 지연, 패킷 손실, 재밍 징후, 인증 실패, 링크 품질
Sensor/AI Output	카메라/LiDAR/Radar 결과, 객체 탐지 결과, 모델 신뢰도
Mission Context	임무계획, 제한구역, 안전한계, 작전규칙
System Log	명령 이력, 로그인 기록, 업데이트 기록, 오류 로그

2. 이상징후 탐지

이상징후	의심 가능한 위협
GNSS와 INS 위치가 크게 불일치	GPS 스푸핑 또는 항법 오염
통신 지연·패킷 손실 급증	재밍 또는 DoS
평소 없던 명령이 GCS/OCU에서 들어옴	명령 주입 또는 계정 탈취
AI 탐지 신뢰도가 갑자기 낮아짐	센서 교란 또는 적대적 예제
동일 표적을 센서별로 다르게 인식	센서 기만 또는 모델 오판단
모델 업데이트 직후 이상 행동 발생	모델 백도어 또는 악성 업데이트
UGV가 지도상 안전구역 밖으로 경로를 생성	SLAM/지도 오염 또는 경로계획 교란

3. 위협 모델과 매핑

단순히 “이상합니다”라고 말하는 것이 아니라, 이 이상징후가 TARA/STRIDE/STPA-Sec/ATLAS 중 어디에 해당하는지 연결해야 한다.

예를 들면:

GNSS-INS 불일치 발생

- STRIDE: Spoofing 가능성
- TARA: 경로 왜곡, 임무 실패, 충돌 위험
- STPA-Sec: 불안전 제어행동 가능성
- 대응: GNSS 신뢰도 하향, INS/비전 기반 항법 전환, 안전속도 제한

AI 객체탐지 신뢰도 급락

- MITRE ATLAS: Evasion/적대적 예제 가능성
- TARA: 표적 오인식, 장애물 회피 실패
- 대응: 센서 재검증, 다중 센서 합의 요구, 인간 확인 요청

이게 에이전트의 핵심이다. 로그를 보는 것에서 끝나지 않고, **이상징후를 위협 시나리오로 해석**해야 한다.

4. 실시간 위험도 재평가

- 같은 이상징후라도 상황에 따라 위험도가 다르다.
- 이에 에이전트는 다음과 같은 요소를 같이 봐야 한다.

평가 요소	의미
피해영향	충돌, 추락, 임무 실패, 정보 유출 가능성
공격가능성	실제 공격일 확률
임무중요도	현재 임무가 얼마나 중요한지
안전한계	고도, 속도, 거리, 제한구역, 충돌 가능성
신뢰도	센서와 모델 판단을 얼마나 믿을 수 있는지

5. 대응 플레이북 추천

- 위험도를 판단한 뒤, 어떤 대응을 할지 추천해야 한다.

위험도	에이전트 행동
Low	로그 수집, 감시 강화, 추가 확인
Medium	센서 재검증, 통신채널 전환, AI 모델 신뢰도 하향
High	안전모드 전환 권고, 임무 일시중지, 수동조종 전환 요청

위험도	에이전트 행동
Critical	즉시 귀환/정지 권고, 인간 승인 요청, 관련 노드 격리

6. 증거 보존

- 사건이 발생했을 때 나중에 분석할 수 있도록 증거를 묶어 저장해야 한다.
- 보존해야 할 것은 다음과 같다:

증거	예시
텔레메트리	위치, 속도, 자세, 시간대별 상태
네트워크 로그	명령 송수신, 인증 실패, 패킷 손실
센서 입력	의심 시점의 카메라/LiDAR/Radar 입력
AI 출력	탐지 결과, 신뢰도, 모델 버전
운용 로그	누가 어떤 명령을 보냈는지
업데이트 로그	펌웨어/모델 업데이트 이력

- 이건 사후 분석, 보고서 작성, 모델 개선, 위협모델 업데이트에 필요하다.

7. 위협모델 업데이트

- 에이전트는 새로 발견된 이상징후나 대응 결과를 다시 위협모델에 반영해야 한다.
- 예를 들어 “특정 환경에서 LiDAR 반사가 반복적으로 AI 오인식을 유발했다”면, 다음에는 그 상황을 새로운 위협 시나리오로 등록해야 한다.
- 즉, 탐지 → 대응 → 증거수집 → 분석 → 위협모델 업데이트 → 더 나은 탐지순환의 구조가 된다.

방어 AI 에이전트가 해야 할 일은 다음 10가지입니다.

1. UAV/UGV의 텔레메트리와 시스템 로그를 실시간 수집한다.
2. 통신 지연, 패킷 손실, 인증 실패, 재밍 징후를 감시한다.
3. GNSS, INS, SLAM, 지도, 비전 기반 위치를 비교해 항법 이상을 탐지한다.
4. 카메라, LiDAR, Radar 등 다중 센서 결과의 불일치를 탐지한다.
5. AI 모델의 출력 신뢰도, 입력 분포 변화, 탐지 결과 급변을 감시한다.
6. 이상징후를 TARA/STRIDE/STPA-Sec/MITRE ATLAS 위협 시나리오에 매핑한다.
7. 피해영향, 공격가능성, 임무중요도, 안전 한계를 기준으로 위험도를 재평가한다.

8. 위험도에 따라 대응 플레이북을 추천하거나 저위험 조치를 자동 수행한다.
9. 고위험 조치는 운용자 승인 또는 정책 엔진을 거치도록 한다.
10. 사고 증거를 보존하고, 분석 결과를 위협모델 지식베이스에 반영한다.